

1 2 9 0



UNIVERSIDADE D
COIMBRA

FUNDAMENTOS DE INTELIGÊNCIA
ARTIFICIAL

Trabalho Prático 2

REALIZADO POR:

Ana Carolina Morais N°2021222056

- email: anamorais@student.dei.uc.pt

Fernanda Fernandes N°2021216620

- email: mrfernandes@student.dei.uc.pt

Pedro Castro N°2021198420

- email: uc2021198420@student.uc.pt

Turma PL4

Turma: PL4

Turma: PL5

INTRODUÇÃO

O presente relatório pretende abordar as componentes de um algoritmo evolucionário, para criar um veículo motorizado. Ao longo deste trabalho, exploraremos os conceitos essenciais envolvidos na concepção e no desenvolvimento de um algoritmo evolucionário, com foco no desenvolvimento de veículos adequados ao cenário em questão. O algoritmo irá construir o veículo com base num conjunto de parâmetros (número de rodas, tamanho das rodas, etc).

Para isso, foi utilizado um simulador com recurso ao 'Software' *Unity*. É através deste simulador, que podemos testar o desempenho do veículo em vários cenários, incluindo trajetos com buracos e quedas.

MODELAÇÃO E DESENVOLVIMENTO


Neste capítulo explicamos todas as etapas envolvidas neste trabalho para o desenvolvimento do Algoritmo Genético. Assim, para esta meta, foi necessário a implementação de funcionalidades básicas do algoritmo, sendo estas, **recombinação**, **seleção de progenitores**, **mutação**, **aptidão** e ainda definir os **parâmetros** do algoritmo.

• RECOMBINAÇÃO (CROSSOVER)

A etapa de recombinação, é o momento onde se recombina os genes para a formação de uma nova geração. Existem diversas técnicas de recombinação, como, por exemplo:

- RECOMBINAÇÃO COM UM PONTO DE CORTE
- RECOMBINAÇÃO COM $N(N > 1)$ PONTOS DE CORTE
- RECOMBINAÇÃO UNIFORME
- Entre outras.

Após a análise dos vários tipos, concluímos que o melhor a implementar seria o operador de **recombinação uniforme**. Na recombinação uniforme, cada gene do descendente tem a mesma probabilidade de ser herdado de qualquer um dos pais. Isso é diferente de outros métodos de recombinação, como o crossover de um ponto de corte ou de dois pontos, onde blocos de genes são copiados de um único pai para os descendentes. Em contraste, na recombinação uniforme, cada gene é considerado separadamente, e para cada gene, escolhe-se aleatoriamente de qual pai ele será copiado. Abaixo, encontra-se uma figura que representa esta mesma recombinação.



Esta é uma técnica muito simples de implementar, porém, tem algumas limitações: por vezes, o indivíduo pode herdar um mau gene de um progenitor e o melhor gene pode ser perdido. No entanto, se tivermos dois pais bons, tipicamente, teremos alta probabilidade de ter um bom filho e, no caso de ele não ser bom, será eliminado na próxima geração (seleção natural).

• MUTAÇÃO

A mutação é um elemento crucial nos algoritmos genéticos, cujo objetivo é manter e introduzir diversidade genética na população de soluções ao longo de gerações. Em suma, a mutação modifica aleatoriamente partes do genótipo (ou seja, os genes) de um indivíduo, o que pode resultar na descoberta de novas e, possivelmente, melhores soluções. Após a recombinação genética é aplicado um processo de mutação. Tal como a recombinação existem vários tipos de mutação, tal como:

- MUTAÇÃO DE BIT FLIP
- MUTAÇÃO UNIFORME
- MUTAÇÃO GAUSSIANA
- Entre outras.

Após a análise dos vários tipos, concluímos que o melhor a implementar seria o algoritmo de **mutação gaussiana**. Pois, esta mutação envolve adicionar um valor aleatório retirado de uma distribuição normal e converge mais rapidamente para soluções ótimas. Neste algoritmo, cada gene dos cromossomos de um indivíduo têm probabilidade igual de sofrer uma mutação, ao qual o novo gene é calculado na base de uma função gaussiana[1].

• SELEÇÃO DE PROGENITORES

A seleção de progenitores é uma etapa importante de um algoritmo genético porque determina quais indivíduos da população atual terão a oportunidade de se reproduzir e transmitir os seus genes para a próxima geração.

A escolha dos pais é um ponto crucial na convergência do nosso algoritmo evolucionário, pois bons pais têm tendência a gerar filhos melhores e mais adequados ao meio. Vários métodos de seleção são utilizados, cada um com características específicas que podem afetar o desempenho do algoritmo.

- SELEÇÃO POR ROLETA
- SELEÇÃO POR TORNEIO
- MÉTODO DE AMOSTRAGEM UNIVERSAL ESTOCÁSTICA
- Entre outras.

Após a análise dos vários tipos, concluímos que o melhor a implementar seria a **seleção por roleta**.

A seleção por roleta em algoritmos genéticos é um método onde a oportunidade de um indivíduo ser escolhido para reprodução é proporcional à sua aptidão. Em outras palavras, indivíduos mais aptos têm maiores segmentos na "roleta" imaginária e, portanto, maior probabilidade de serem selecionados. Este método simples favorece os melhores indivíduos, o que pode acelerar a convergência para soluções de alta qualidade. No entanto, uma desvantagem é que pode levar à perda de diversidade genética, pois indivíduos altamente aptos podem dominar rapidamente a população.

• APTIDÃO

A aptidão é uma métrica crucial em algoritmos evolucionários para avaliar se um indivíduo possui características genéticas adequadas para desempenhar bem a tarefa designada. Esta função, chamada de função de aptidão, é essencial para orientar todo o processo de seleção, mutação e recombinação, selecionando indivíduos com alta aptidão para reprodução. Isso favorece a criação de novas gerações que possuem características genéticas mais propensas a resolver o problema proposto.

No momento da avaliação de um indivíduo, obtemos um valor que corresponde à qualidade do mesmo. Este valor será maior quanto melhor for o desempenho do indivíduo. É bastante importante que esta função esteja bem definida, para evitar excluir indivíduos que representem uma boa solução, o que irá, posteriormente, influenciar a evolução deste mesmo algoritmo.

Neste contexto, elaborámos uma função de aptidão que contém todas as variáveis disponíveis do indivíduo, dando diferentes pesos a cada uma, uma vez que, por exemplo, a **distância** e o **tempo decorrido** são indicadores diretos do desempenho do veículo, outro caso, o **número de rodas** e a **massa do carro**: são variáveis que podem afetar a estabilidade e a eficiência do veículo. Embora possam parecer menos importantes à primeira vista, elas podem ter implicações significativas no comportamento dinâmico do carro, influenciando como ele responde em diferentes cenários.

Ponderámos descartar algumas variáveis para simplificar a função, mas resultaria na perda de informação crucial que afeta a precisão da simulação.

Assim, ao construir, desta forma, a função de aptidão, não só amplia a profundidade e a aplicabilidade dos resultados da simulação, mas também aumenta a capacidade de alcançar um 'design' otimizado e funcionalmente completo do veículo.

```
// QUANTO MAIS LONGE O CARRO CHEGA, MELHOR É O SEU DESEMPENHO.
FLOAT DISTANCEWEIGHT = 1.0F;
FITNESS += DISTANCE * DISTANCEWEIGHT;

// QUANTO MAIS TEMPO O CARRO LEVA PARA COMPLETAR A PISTA, PIOR É O SEU DESEMPENHO.
FLOAT TIMEWEIGHT = -0.5F;
FITNESS += ELAPSEDTIME * TIMEWEIGHT;

// CARROS COM MAIS RODAS PODEM SER MAIS PESADOS E MENOS EFICIENTES
FLOAT WHEELPENALTY = -0.1F;
FITNESS += NUMBEROFWHEELS * WHEELPENALTY;

// CARROS MAIS PESADOS PODEM SER MAIS DIFÍCEIS DE CONTROLAR
FLOAT MASSPENALTY = -0.05F;
FITNESS += CARMASS * MASSPENALTY;

// CARROS QUE COMPLETAM A PISTA TÊM UM PESO EXTRA
FLOAT COMPLETIONBONUS = 100.0F;
FITNESS += ROADCOMPLETED * COMPLETIONBONUS;

FLOAT AVERAGEVELOCITYWEIGHT = 0.2F;
FLOAT AVERAGEVELOCITY = SUMVELOCITIES / VELOCITIES.COUNT;
FITNESS += AVERAGEVELOCITY * AVERAGEVELOCITYWEIGHT;

// ACELERAÇÕES MÉDIAS PODEM INDICAR UM BOM USO DE POTÊNCIA.
FLOAT AVERAGEACCELERATIONWEIGHT = 0.1F;
FLOAT AVERAGEACCELERATION = SUMACCELERATIONS / ACCELERATIONS.COUNT;
FITNESS += AVERAGEACCELERATION * AVERAGEACCELERATIONWEIGHT;

// FORÇAS MÉDIAS PODEM INDICAR UM BOM USO DE POTÊNCIA.
FLOAT AVERAGEFORCEWEIGHT = 0.1F;
FLOAT AVERAGEFORCE = SUMTOTALFORCES / FORCES.COUNT;
FITNESS += AVERAGEFORCE * AVERAGEFORCEWEIGHT;
```

• PARAMETRIZAÇÃO

Para esta fase são especificados os parâmetros do algoritmo evolucionário. Assim, para este projeto foram utilizados os seguintes parâmetros:

- Probabilidade de Mutação
- Tamanho do Elitismo
- Probabilidade de Crossover
- Número de Gerações

Estes parâmetros visam gerir como o algoritmo evolucionário se irá comportar. Assim, é possível alterar os valores ao longo das experiências de forma mais fácil.

• EXPERIMENTAÇÃO E ANÁLISE – GAPROAD

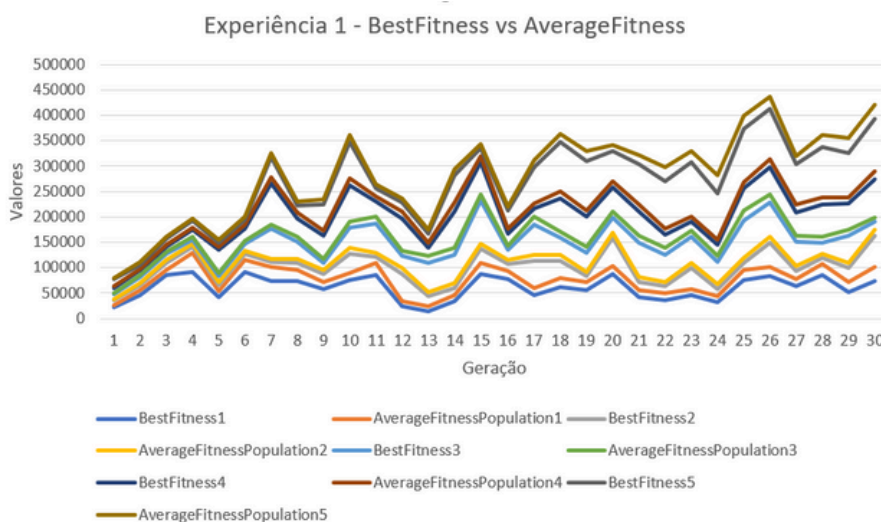
Após termos as funções devidamente implementadas, é vital testar as funcionalidades do algoritmo. Assim, vamos tentar estabelecer os melhores parâmetros, a partir da tabela abaixo. Uma vez que, ao contrário da tabela do enunciado que contém o parâmetro do torneio, como implementámos a seleção por roleta, esse parâmetro não se encontra na nossa tabela. Não esquecendo que para cada experiência é necessário realizar 5 execuções da mesma, para obter dados mais fidedignos.

	Mutação	Elitismo	Crossover	Número Gerações
Experiência 1	0.05	0	0.5	30
Experiência 2	0.2			
Experiência 3	0.05	2		
Experiência 4	0.2			

• EXPERIÊNCIA 1

Antes da realização desta experiência, existem algumas questões teóricas que podemos presumir. Uma vez que não apresenta qualquer valor de elitismo, não se selecionam os melhores agentes da geração atual para a próxima, o que pode prejudicar a evolução, impedindo a geração de novos veículos a partir dos melhores exemplares. Uma baixa probabilidade de mutação pode ser benéfica se já existirem carros eficazes, mantendo a qualidade dos descendentes próximos ao progenitor. Porém, se não houver bons indivíduos iniciais, essa mesma baixa probabilidade de mutação dificultará a evolução. Portanto, o impacto da probabilidade de mutação depende muito dos genótipos iniciais, podendo ser vantajoso mantê-la baixa se estes forem bons, ou necessitar de aumento se forem inadequados.

A partir da nossa função de aptidão, tivemos o seguinte resultado, o gráfico mostra a relação do Best Fitness com a Average Fitness.



Com base nos resultados obtidos, e, tendo em consideração a falta de elitismo, como explicado anteriormente, é de facto notória, pois não teremos pontos de referência para gerações futuras e, isso prejudicará o algoritmo a manter a estabilidade na procura de agentes que terminem os percursos. É de realçar que para além dos nossos valores serem bastantes altos, uma vez que a nossa função de aptidão tem em conta as demais variáveis, existem uma grande instabilidade entre os melhores indivíduos de cada geração onde a evolução será de certo modo aleatória.

De notar, também as baixas *AverageFitness*, tendo em conta todas as vezes que executamos a experiência, comprovando assim, que esta não será de todo a experiência mais aconselhada para atingir o nosso objetivo.

• EXPERIÊNCIA 2

A base desta experiência é muito semelhante à anterior, apenas é alterado o valor da mutação, para um valor maior. Em contrapartida, uma alta probabilidade de mutação pode ter benefícios se já houverem carros eficazes na população, mantendo a qualidade dos descendentes próxima à do progenitor. No entanto, se os indivíduos iniciais não forem bons o suficiente, uma alta probabilidade de mutação pode dificultar a evolução. Assim, o impacto da probabilidade de mutação depende significativamente da qualidade dos genótipos iniciais.

A partir da nossa função de aptidão, tivemos o seguinte resultado, o gráfico mostra a relação do Best Fitness com a Average Fitness.



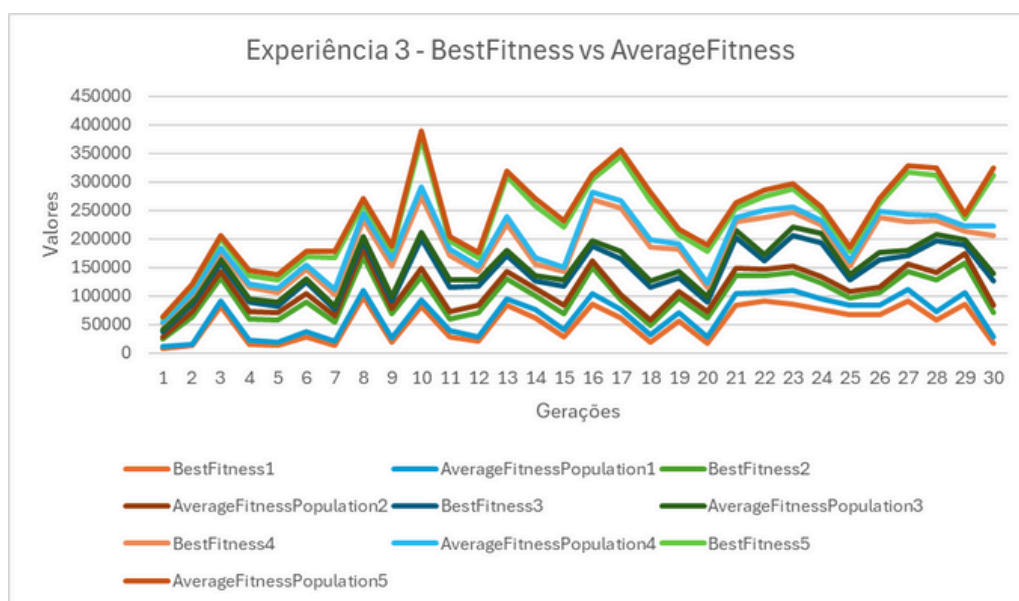
Com base nos resultados obtidos, e em comparação com a experiência anterior é de notar que os valores da experiência 2 são significativamente menores que os da experiência 1. Dado isto, percebemos que o aumento da probabilidade de mutação não é benéfica neste caso, continuando a existir uma grande instabilidade entre os melhores indivíduos de cada geração onde a evolução continua de certo modo aleatória.

Mais uma vez são bastante notórios os picos baixos da AverageFitness, tendo em conta todas as vezes que executamos a experiência, comprovando mais uma vez, que esta não é a experiência mais aconselhada para atingir o nosso objetivo.

• EXPERIÊNCIA 3

Antes da realização desta experiência, existem algumas questões teóricas que podemos presumir. Sendo que o valor de elitismo aumentou para 2, e o valor da mutação continua a ser 0.05. Ou seja, ao se manter uma probabilidade de mutação baixa poderá vir a ser benéfica caso já existam carros eficazes, mantendo assim a qualidade dos descendentes próxima à dos progenitores. E tendo em conta que o valor do elitismo aumentou, a escolha dos melhores agentes da geração atual para a seguinte será muito mais eficaz.

A partir da nossa função de aptidão, tivemos o seguinte resultado, o gráfico mostra a relação do Best Fitness com a Average Fitness.




Com base nos resultados obtidos, e, tendo em consideração as suas alterações e as experiências anteriores, vemos uma estabilidade maior na evolução dos veículos, sendo que, numa primeira fase, ainda não se encontrou um veículo que consiga terminar o percurso, melhorando gradualmente o seu fitness ao longo das gerações. Isto acontece, uma vez que existe elitismo, pois ao possibilitar a escolha dos progenitores mais aptos, conseguimos gerar gerações cada vez melhores. A partir do momento, que um veículo consegue acabar a corrida, todas as gerações seguintes também o conseguem.

• EXPERIÊNCIA 4





Antes da realização desta experiência, existem algumas questões teóricas que podemos presumir. Uma vez que o valor de elitismo aumenta para 2, e a probabilidade de mutação aumenta para 0.2, é de realçar que com o aumento de probabilidade de mutação, a probabilidade de alterar progenitores benéficos para a experiência aumentará também, mas, por outro lado, a probabilidade de alterar progenitores com características menos favoráveis irá também ser superior.

A partir da nossa função de aptidão, tivemos o seguinte resultado, o gráfico mostra a relação do Best Fitness com a Average Fitness.



Com base nos resultados obtidos, e, tendo em consideração que se alterou a probabilidade de mutação de 0.05 para 0.2 (relativamente à experiência 3), o que, tecnicamente, faz com que haja alterações aos *offsprings* sejam mais significativas. Nesta experiência, reparamos que tem uma ligeira progressão. É uma progressão lenta relativamente à experiência anterior, pois só difere no valor da mutação. Isto acontece, porque quando um indivíduo tem uma boa prestação e é selecionado como progenitor da próxima geração, o seu descendente perde as suas boas características, devido à aleatoriedade do algoritmo.

• OBSERVAÇÃO




Após a realização da primeira meta e dos gráficos a cima representados, percebemos que a escolha dos gráficos não foi a melhor, pois tem demasiada informação espalhada e tornam se confusos. Daí decidimos conglomerar a informação e fazer gráficos com média e desvio padrão. As conclusões são semelhantes, pois a experiência 3 tal como nos gráficos anteriores é a que se destaca mais, mantendo uma média mais ou menos constante, ao contrário dos outros gráficos, onde se observam bastantes mais picos negativos e positivos. O objetivo ao realizar este tipo de dados é procurar uma experiência que contenham funções de média monótonas crescentes, sendo o caso da experiência 3.

EXPERIÊNCIA 3 ATRAVÉS DA SELEÇÃO POR TORNEIO


Uma vez que realizámos as experiências anteriores com a seleção de progenitores através da roleta, iremos agora experimentar a seleção através do torneio, para averiguar qual seria a melhor ferramenta. Assim, como concluímos que os melhores valores a testar são os da experiência 3, iremos agora testar esses valores combinados com o torneio de 5 e o de 2 e, no final, concluir se é melhor utilizar torneio em vez da roleta ou não.

Para **tournamentSize = 5**;



Para **tournamentSize = 2**;

Com tamanho de torneio 2 a probabilidade de achar um indivíduo mais apto irá diminuir abruptamente, visto que iremos estar a analisar e a comparar um número muito reduzido de agentes. Deste modo, iremos ter um processo de evolução dos indivíduos pouco eficiente, já que estes irão evoluir sempre de agentes escolhidos aleatoriamente.



Comparando agora os gráficos do torneio e da roleta, facilmente percebemos que a roleta é muito mais estável, do que o torneio. Percebemos então que fizemos a escolha certa e manteremos a **roleta** nos testes futuros.

EXPERIÊNCIA 3 GAP ROAD





Uma vez que a função de fitness mencionada anteriormente envolve toda a informação dada, o que não é uma grande ajuda, decidimos melhorá-la, ou seja, destacamos alguns aspetos e retiramos outros. A forma, de como, concluímos esta expressão foi por meio de vários testes, com diferentes termos, diferentes parâmetros, à qual a expressão com maior progresso, foi a seguinte:

$$\text{fitness} = 0.3f * \text{Distance} + 100.0f * \text{RoadCompleted} + 2f * \text{Distance} / (\text{ElapsedTime} + 1.0f)$$

A diferença desta expressão para a anterior é a inclusão da velocidade média, calculada de forma correta, e a exclusão da informação relativa à massa do carro, ao número de rodas, à lista de velocidades, aceleração e força e as suas respetivas somas.


Esta escolha foi optada, uma vez que é necessário obter veículos capazes de terminar o percurso no menor tempo possível e de forma mais eficiente num cenário em que contém diferentes “gaps”. Demos uma maior importância à **distância máxima** percorrida, mas ainda uma maior importância à **velocidade média** e se o carro consegue terminar o percurso (**RoadCompleted**), pois é mais vantajoso olhar para os agentes que conseguem chegar mais longe no mesmo percurso.

• ANÁLISE DOS RESULTADOS PARA O CENÁRIO GAP ROAD



Com base nos gráficos apresentados, a partir da análise dos dois primeiros gráficos, fica evidente que, geralmente, o algoritmo é capaz de identificar uma solução de forma rápida. Isso é vantajoso, pois facilita a descoberta de mais agentes aptos a superar o cenário do GapRoad, implicando assim que a evolução de uma geração para a próxima ocorre de maneira eficaz. No entanto, esta informação seria mais evidente se realizássemos mais experiências em que íamos aumentando o número de gerações gradualmente. Ao observar o gráfico da média e do desvio padrão do BestFitness, conseguimos visualizar que é uma função monótona crescente, sendo que, claro que procuramos que estabilize num certo ponto. É de realçar que, por exemplo, na repetição 5, o carro com o melhor fitness de geração para geração pode diminuir o seu valor de fitness.


Vamos agora analisar os melhores veículos de cada repetição.




MELHOR CARRO PARA O GAP ROAD
1ª REPETIÇÃO




MELHOR CARRO PARA O GAP ROAD
2ª REPETIÇÃO



MELHOR CARRO PARA O GAP ROAD
3ª REPETIÇÃO



MELHOR CARRO PARA O GAP ROAD
4ª REPETIÇÃO







MELHOR CARRO PARA O GAP ROAD
5ª REPETIÇÃO

Ao observar, os melhores carros de todas as experiências podemos concluir que o por exemplo ter menor ou maior massa, não é um critério que ajuda a definir o melhor carro do cenário, neste caso o melhor caso do cenário é o da experiência 3, que tem uma massa relativamente maior ou menor que outros carros de outras experiencias. Outra coisa que podemos concluir é que carros com número de rodas superior a 5, e de tamanho relativamente grande e semelhante são benéficos neste cenário. É de notar também que o carro da experiência 1, 4 e 5 tem as rodas relativamente mais afastadas do que os das restantes experiências.

EXPERIÊNCIA 3 HILL ROAD

Após a avaliação das componentes do algoritmo genético e a análise das experiências, começamos por testar este cenário utilizando a melhor expressão de fitness encontrada no cenário anterior e os parâmetros da experiência 3. Neste cenário, as inclinações e declives são os principais desafios. A função de aptidão incentiva não apenas a término do percurso, mas também uma maior eficiência no tempo percorrido. Portanto, veículos que conseguem manter uma velocidade constante e superar inclinações sem perder muita energia ou tempo são mais valorizados. Isso pode levar a uma evolução de veículos com melhor distribuição de peso e tração, adaptados para lidar com subidas e descidas. Assim, podemos observar que:

• ANÁLISE DOS RESULTADOS PARA O CENÁRIO HILL ROAD




Os gráficos analisados demonstram uma progressão notável no desempenho dos veículos ao longo das 30 gerações no cenário Hill Road, utilizando a função de aptidão definida. Observa-se uma melhoria contínua e evidente na aptidão máxima, como indicado pelo aumento dos valores em cada geração para diferentes configurações de veículos. Este aumento sugere que os veículos estão a evoluir para completar o percurso com maior eficiência, equilibrando habilmente a distância percorrida e o tempo utilizado, conforme incentivado pela função de aptidão.

A estabilidade na velocidade média dos veículos, juntamente com a convergência da média de aptidão e a redução no desvio padrão observados, indica que a população está a convergir para soluções mais eficientes e consistentes. O rápido ganho inicial em aptidão seguido por um ajuste mais gradual destaca uma adaptação robusta dos veículos às inclinações do cenário Hill Road, otimizando características como a capacidade de escalada e a manutenção da velocidade em terrenos desafiadores.


Em conclusão, os resultados reflectem a eficácia do algoritmo evolutivo em adaptar os veículos para enfrentar e superar as complexidades do terreno inclinado, demonstrando uma evolução significativa que prioriza a eficiência energética e a desempenho geral. A consistência no desempenho ao longo das gerações reforça a seleção de traços genéticos benéficos, evidenciando uma otimização bem-sucedida dos veículos para o cenário proposto.




MELHOR CARRO PARA O HILL ROAD
1ª REPETIÇÃO




MELHOR CARRO PARA O HILL ROAD 2ª
REPETIÇÃO



MELHOR CARRO PARA O HILL ROAD 3ª
REPETIÇÃO



MELHOR CARRO PARA O HILL ROAD 4ª
REPETIÇÃO




MELHOR CARRO PARA O HILL ROAD 5ª
REPETIÇÃO

Ao observar os melhores carros de cada experiência, podemos concluir que em todos os casos uma massa superior a 250 foi benéfica, mas mais uma vez não é dos pontos mais importantes, pois há bastante discrepância entre o valor da massa de cada carro nas 5 experiências. Por outro lado algo que vemos em comum nas 5 experiências é o número, e aspeto das rodas, todos tem mais de 5 rodas, em que mais ou menos metade são maiores e o resto menor. Também é de notar que a maioria tem as rodas mais juntas, sendo o carro da melhor experiência o que tem as rodas mais condensadas no espaço e com maior quantidade de rodas grandes.


EXPERIÊNCIA 3 ROCKY HILL ROAD

Após a avaliação das componentes do algoritmo genético e a análise das experiências, começamos por testar este cenário utilizando a expressão de fitness encontrada no cenário “Gap road” e os parâmetros da experiência 3. Neste cenário complexo, o término do percurso ganha uma importância adicional devido aos desafios adicionais do terreno irregular. A função favorece os veículos que não apenas conseguem ultrapassar as rochas e outros obstáculos, mas que o fazem de forma eficiente. A capacidade de manter uma boa velocidade apesar das condições adversas será uma característica evolutiva chave.


• ANÁLISE DOS RESULTADOS PARA O CENÁRIO ROCKY HILL ROAD




A análise dos gráficos sugere que a função de aptidão foi eficaz em promover a evolução de veículos que conseguem lidar com o terreno acidentado e inclinado do cenário Rocky Hill Road. A rápida convergência para altos valores de aptidão e a estabilidade nas distâncias percorridas indicam que os veículos desenvolveram capacidades robustas para superar os desafios impostos. Além disso, a adaptação a variações de velocidade sugere uma otimização contínua dos veículos para equilibrar a velocidade e a capacidade de superar obstáculos físicos, demonstrando uma evolução significativa em resposta às condições do ambiente.




MELHOR CARRO PARA O ROCKY HILL
 ROAD 1ª REPETIÇÃO




MELHOR CARRO PARA O ROCKY HILL
 ROAD 2ª REPETIÇÃO



MELHOR CARRO PARA O ROCKY HILL
 ROAD 3ª REPETIÇÃO



MELHOR CARRO PARA O ROCKY HILL
 ROAD 4ª REPETIÇÃO



MELHOR CARRO PARA O ROCKY HILL
 ROAD 5ª REPETIÇÃO

Ao observar os melhores carros de cada experiência, podemos concluir que na maioria dos casos a massa é elevada, sendo superior a 300, logo mais uma vez o peso do carro é benéfico para a eficácia. Neste caso vemos mais discrepância entre o formato dos carros, temos uns mais condensados, outros com pontos mais altos, ou afastados, sendo o que é mais equilibrado entre altura e largura o mais benéfico no cenário. Mais uma vez temos carros com grandes rodas, onde o tamanho das rodas é bastante semelhante entre si, havendo muito pouca oscilação.

DESAFIO EXTRA – NOVA FUNÇÃO DE APTIDÃO

Como comportamento extra, decidimos implementar uma nova função de aptidão que valorizasse também a massa e o número de rodas, para assim conseguirmos comparar com a função de aptidão anterior. Assim, para cada cenário, executou-se a seguinte função de aptidão.

fitness = 10000f * RoadCompleted + 40f * Distance + (5f * (1f / CarMass)) + (15f * (1f / NumberOfWheels)) + 200f * maxVelocity + 150f * (Distance / (EllapsedTime + 1.0f));

Assim, foi necessário pensar quais os parâmetros mais importantes para chegar à melhor função de fitness possível. Tal como a função de aptidão, anterior demos uma maior importância à **distância** máxima percorrida e se o carro consegue terminar o percurso (**RoadCompleted**), pois é mais vantajoso olhar para os agentes que conseguem chegar mais longe no mesmo percurso.

Outro fator importante, como referido anteriormente, é a **massa do carro**, pois deverá ser a mais pequena possível, para que o veículo não necessite de tanta velocidade para conseguir subir, isto resulta, então, numa pequena penalização a agentes com pesos maiores, isto devido ao cenário "Hill Road". Da mesma forma em que consideramos a massa do carro, considerámos o **número de rodas**, que deverá ser o menor possível para evitar que o agente tenha uma grande massa e, ao mesmo tempo, tentar manter a estabilidade do agente em cada cenário.





A **velocidade máxima** é um aspeto importantíssimo, na medida, em que um agente deverá tomar partido da aceleração que ganha na descida da primeira colina para conseguir ultrapassar a colina seguinte, no cenário "Hill Road". O momento em que se alcança um "vale" corresponde ao ponto de velocidade máxima, o que se justifica pela necessidade do veículo exercer maior força para começar a subir uma colina. Neste ponto, a energia cinética é também mais elevada, proporcionando assim maior ímpeto ao veículo.

Relativamente aos pesos, reforçamos a importância do agente completar o percurso. Atribuímos um peso significativo à velocidade máxima para assegurar que os agentes têm força suficiente para superar as colinas. A velocidade média também é valorizada, premiando agentes que mantêm uma boa velocidade contínua. A adição de 1.0f ao tempo evita a divisão por zero e suaviza o efeito de tempos de execução muito curtos, este último caso também acontece com a função de aptidão anterior.

Nota: Inicialmente, o nosso desafio extra seria desenvolver um novo cenário para realizar novos casos de teste, ao qual ainda conseguimos realizar alguns testes mudando os valores do nosso cenário para criar um cenário que retratasse a superfície de uma cratera lunar, mas devido à complexidade, o Unity ia abaixo, o que optámos por uma nova função de aptidão para estes cenários.

DESAFIO EXTRA – ANÁLISE DOS RESULTADOS

• GAP ROAD







A função de aptidão utilizada no cenário Hill Road parece eficaz em incentivar os veículos a otimizar múltiplos aspetos do seu desempenho, incluindo a completude do percurso, eficiência temporal, e a maximização da velocidade. A convergência rápida para altos valores de aptidão e a estabilização subsequente indicam que os veículos estão se adaptando bem ao cenário, alcançando consistentemente o desempenho desejado. A função de aptidão promove uma abordagem equilibrada, valorizando aos veículos que terminam o percurso e a eficiência, ao mesmo tempo, em que recompensa as características físicas como a menor massa e o menor número de rodas, levando a uma evolução direcionada e eficiente dos veículos.

• HILL ROAD



A função de aptidão utilizada no cenário Hill Road parece eficaz em incentivar os veículos a otimizar múltiplos aspetos do seu desempenho, incluindo a completude do percurso, eficiência temporal, e a maximização da velocidade. A convergência rápida para altos valores de aptidão e a estabilização subsequente indicam que os veículos estão se adaptando bem ao cenário, alcançando consistentemente o desempenho desejado. A função de aptidão promove uma abordagem equilibrada, valorizando aos veículos que terminam o percurso e a eficiência, ao mesmo tempo, em que recompensa as características físicas como a menor massa e o menor número de rodas, levando a uma evolução direccionada e eficiente dos veículos.

• ROCKY HILL ROAD



Os dados demonstram que a função de aptidão complexa utilizada no cenário Rocky Hill Road foi efetiva em direcionar a evolução dos veículos para maximizar não apenas o término do percurso, mas também a sua eficiência em termos de distância percorrida, massa do veículo, número de rodas e velocidade. A rápida convergência das métricas de aptidão e a estabilização nas distâncias percorridas indicam que os veículos adaptaram-se bem às exigências do terreno acidentado e inclinado, alcançando um equilíbrio entre as várias componentes da função de aptidão. Esta análise é fundamental para entender como as características específicas dos veículos contribuem para o seu desempenho geral no cenário Rocky Hill Road, destacando o sucesso do algoritmo evolutivo em produzir veículos robustos e eficientes.

CONCLUSÃO

Ao longo do desenvolvimento deste trabalho, foram adquiridos conhecimentos acerca de como um algoritmo evolucionário funciona, nomeadamente os seus parâmetros (mutação, crossover, seleção, ...). Através deste algoritmo desenvolvemos competências em como formular uma função de fitness: atribuição de pesos para as diferentes características utilizadas, quais características escolher e como estas influenciam a evolução dos agentes.

Apercebemo-nos também da natureza estocástica deste tipo de algoritmo, pelo que foi necessária a realização de várias experiências para chegar aos melhores parâmetros. Finalmente, já na realização de experiências nos cenários propostos (GapRoad, HillRoad e RockyHillRoad) notámos que por vezes para um agente terminar estes mesmos percursos dependerá mais da sua fisionomia do que das suas características (velocidade, massa, número de rodas, ...).